Ashington[1]

[1]Wuhan Textile University, Ashington258@proton.me

2026-09-15

微分、线性近似及其几何含义

1 一元微分

1.1 导数的定义

设 $f(x)$ 是一个定义在某开区间上的实值函数，且在点 x_0 处可导。其导数 $f'(x_0)$ 定义为极限形式：

$$f'(x_0) = \lim_{h \to 0} \frac{f(x_0 + h) - f(x_0)}{h}$$

此定义描述了函数在 x_0 处的局部变化率

1.2 函数局部的行为表征 (函数的变化量)

令 $\Delta x = x - x_0$，则实际函数增量为

$$\Delta y = f(x_0 + \Delta x) - f(x_0).$$

根据导数的定义，当 $\Delta x \to 0$ 时有

$$\Delta y = f'(x_0)\Delta x + o(\Delta x)$$

$$\Delta y = \underbrace{f'(x_0)\Delta x}_{\text{线性主部}} + \underbrace{o(\Delta x)}_{\text{相对于}\Delta x\text{ 可忽略的余项}}$$

当 Δx 足够小时，忽略余项可得到线性近似：

$$\Delta y \approx f'(x_0)\Delta x$$

定义以 x_0 为展开点的线性近似函数

$$L_{x_0}(x) := f(x_0) + f'(x_0)(x - x_0).$$

于是

$$f(x) = L_{x_0}(x) + o(x - x_0), \qquad x \to x_0,$$

或在近似意义下写为

$$f(x) \approx f(x_0) + f'(x_0)(x - x_0).$$

该线性近似可以表征函数的局部行为。线性近似函数在整个坐标轴上定义后，其图像就是切线；但它通常不等于原函数，只在 x_0 附近近似原函数。

切线是函数 $y = L_{x_0}(x)$，其方程为：

$$y = f(x_0) + f'(x_0)(x - x_0).$$

其中 x 在 x_0 的邻域内时，切线函数是原函数的近似。

1.3 微分的定义

函数在 x_0 处的**微分**是一个关于输入增量的线性映射。对任意增量 dx，定义

$$\mathrm{d}y := \mathrm{d}f_{x_0}(dx) = f'(x_0)\,\mathrm{d}x.$$

结合前述增量表达式，我们有：

$$\Delta y = dy + o(\Delta x)$$

当取 $dx = \Delta x$ 时，微分 dy 表示切线给出的线性增量，而 $o(\Delta x)$ 是线性近似误差。一般而言，dy 与实际增量 Δy 并不相等。

1.4 线性近似和切线方程

我们通过微分描述函数的局部行为。从几何角度看，微分对应于函数在 x_0 处的切线增量。函数在 x_0 处的切线方程为：

$$y - f(x_0) = f'(x_0)(x - x_0)$$

基于此切线方程，我们可以得到函数 $f(x)$ 在 x_0 附近的线性近似：

$$f(x) \approx L_{x_0}(x) = f(x_0) + f'(x_0)(x - x_0).$$

若令 $x = x_0 + h$ （即 $h = x - x_0$ ），则等价形式为：

$$f(x_0 + h) \approx f(x_0) + f'(x_0)h$$

然而，这种线性近似仅在 h 充分小时有效，且精度有限，因为它忽略了 $o(\Delta x)$ 中的高阶项。

为了更精确地描述函数在 x_0 附近的局部行为，需要引入高阶导数进行修正。这自然引出了泰勒公式，通过高阶项对函数进行多项式近似，后续分析将进一步展开。

1.5 Taylor 公式引入

在线性近似中，我们利用函数在一点的导数（即一阶信息）来估计函数在该点附近的取值。然而，为了更精确地刻画函数的局部行为，我们可以进一步引入函数的高阶导数，构造出**更高阶的近似表达式**。

设函数 $f(x)$ 在包含 x_0 与 x 的区间上具有 $(n+1)$ 阶导数，且 $f^{(n)}$ 在该区间上连续，记 $h = x - x_0$。则 Taylor 公式为：

$$f(x) = f(x_0) + f'(x_0)h + \frac{f''(x_0)}{2!}h^2 + \cdots + \frac{f^{(n)}(x_0)}{n!}h^n + R_n(h)$$

其中 $R_n(h)$ 为**余项**，表示高阶近似的误差项，具体形式依赖于所采用的余项形式（如拉格朗日型、皮亚诺型、积分型等）。最常见的为**拉格朗日余项**，其形式为：

$$R_n(h) = \frac{f^{(n+1)}(\xi)}{(n+1)!}h^{n+1}, \quad \text{其中 } \xi \in (x_0, x)$$

当 $h \to 0$ 时，$R_n(h) = O(h^{n+1})$。去掉余项后得到的前 $n+1$ 项称为 **Taylor 多项式**：

$$T_n(x) = \sum_{k=0}^{n} \frac{f^{(k)}(x_0)}{k!}(x - x_0)^k$$

特别地，$n = 1$ 时，Taylor 多项式即为线性近似：

$$f(x) \approx f(x_0) + f'(x_0)(x - x_0)$$

这正是前面微分所提供的**一阶逼近**。因此，可以将微分视为 Taylor 展开在一阶截断时所保留的主导部分。

这也恰好是 Lagrange 中值定理的形式:

$$f(b) - f(a) = f'(\xi)(b - a)$$

因此这类思想都是用线性量 (或更精确一步的使用多项式) 去描述函数的局部行为。

2 多元函数

2.1 偏导数与全微分

偏导数　对于多元函数 $f : \mathbb{R}^n \to \mathbb{R}$ ，设点 $\mathbf{x}_0 = (x_{01}, x_{02}, \ldots, x_{0n})$ 。函数关于第 i 个变量的偏导数定义为：

$$\frac{\partial f}{\partial x_i}(\mathbf{x}_0) = \lim_{h \to 0} \frac{f(x_{01}, \ldots, x_{0i} + h, \ldots, x_{0n}) - f(\mathbf{x}_0)}{h}$$

偏导数表示函数沿 x_i 轴方向的变化率。

偏导数只描述沿坐标轴方向的变化。它们的存在本身并不能推出函数可微；只有在可微时，整体增量才可以由这些偏导数构成的线性组合统一近似。

全微分 设函数

$$f : \mathbb{R}^n \to \mathbb{R}, \quad \mathbf{x}_0 \in \mathbb{R}^n,$$

若 f 在点 $\mathbf{x}_0$ **可微**，则存在一个线性映射 $L : \mathbb{R}^n \to \mathbb{R}$，使得

$$f(\mathbf{x}_0 + \Delta\mathbf{x}) - f(\mathbf{x}_0) = L(\Delta\mathbf{x}) + o(|\Delta\mathbf{x}|), \quad \Delta\mathbf{x} \to 0.$$

其中：

- $L(\Delta\mathbf{x})$ 是**线性主部**，由梯度给出：

$$L(\Delta\mathbf{x}) = \nabla f(\mathbf{x}_0) \cdot \Delta\mathbf{x} = \sum_{i=1}^{n} f_{x_i}(\mathbf{x}_0)\, \Delta x_i.$$

- 余项 $o(|\Delta\mathbf{x}|)$ 与 $|\Delta\mathbf{x}|$ 相比可以忽略。

因此，当 $\Delta\mathbf{x} = (\Delta x_1, \dots, \Delta x_n)$ 很小时，函数增量近似为：

$$\Delta f = f(\mathbf{x}_0 + \Delta\mathbf{x}) - f(\mathbf{x}_0) \approx \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\mathbf{x}_0)\, \Delta x_i.$$

这一定义出的线性近似称为 **全微分**，记作：

$$df(\mathbf{x}_0)[d\mathbf{x}] := \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\mathbf{x}_0)\, dx_i.$$

由此自然引出可微的条件，即余项无穷小 **可微的条件**

函数 $f : \mathbb{R}^n \to \mathbb{R}$ 在点 $\mathbf{x}_0$ 可微，当且仅当

$$\lim_{\Delta\mathbf{x} \to 0} \frac{f(\mathbf{x}_0 + \Delta\mathbf{x}) - f(\mathbf{x}_0) - \sum_{i=1}^{n} f_{x_i}(\mathbf{x}_0)\Delta x_i}{\|\Delta\mathbf{x}\|} = 0.$$

线性近似与几何含义 全微分提供了函数的线性近似：

$$f(\mathbf{x}_0 + \Delta\mathbf{x}) \approx f(\mathbf{x}_0) + \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\mathbf{x}_0)\Delta x_i$$

几何上，这对应于函数图形在 $\mathbf{x}_0$ 处的**切超平面**，类似于一元函数的切线。

2.2 方向导数与梯度

方向导数 多元函数不仅沿坐标轴变化，我们还关心沿任意方向的变化率。设 $\mathbf{u} = (u_1, \dots, u_n)$ 为单位向量（$\|\mathbf{u}\| = 1$ ），方向导数定义为：

$$D_{\mathbf{u}} f(\mathbf{x}_0) := \lim_{h \to 0} \frac{f(\mathbf{x}_0 + h\mathbf{u}) - f(\mathbf{x}_0)}{h}$$

它表示函数沿 $\mathbf{u}$ 方向的变化率。

我们关心函数沿哪个方向的变化率最大，即求单位方向上的方向导数最大值：

$$\max_{\|\mathbf{u}\|=1} D_{\mathbf{u}} f(\mathbf{x}_0).$$

$$\begin{aligned} D_{\mathbf{u}} f(\mathbf{x}_0) &:= \lim_{h \to 0} \frac{f(\mathbf{x}_0 + h\mathbf{u}) - f(\mathbf{x}_0)}{h}, \quad \|\mathbf{u}\| = 1 \\ &= \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\mathbf{x}_0)\, u_i \\ &= \nabla f(\mathbf{x}_0) \cdot \mathbf{u} \\ &= \|\nabla f(\mathbf{x}_0)\|\, \|\mathbf{u}\| \cos\theta = \|\nabla f(\mathbf{x}_0)\| \cos\theta, \end{aligned}$$

其中 θ 是 $\nabla f(\mathbf{x}_0)$ 与 $\mathbf{u}$ 之间的夹角。

其中 $x_0 = (x_{01}, x_{02}, \dots, x_{0n})$

当 $\nabla f(\mathbf{x}_0) \neq 0$ 时，且仅当 $\mathbf{u}$ 与 $\nabla f(\mathbf{x}_0)$ 同方向时，方向导数达到最大值 $\|\nabla f(\mathbf{x}_0)\|$。若 $\nabla f(\mathbf{x}_0) = 0$，则所有单位方向的方向导数均为 0。

故我们将 $\nabla f(\vec{x}_0)$ 称为梯度，记为

$$\nabla f(\vec{x}_0) = \left(\frac{\partial f}{\partial x_1}(\vec{x}_0), \dots, \frac{\partial f}{\partial x_n}(\vec{x}_0) \right)$$

全微分的梯度表达对于 $f : \mathbb{R}^n \to \mathbb{R}$ ，若在 $\mathbf{x}_0$ 可微，则

$$df(\mathbf{x}_0) = \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\mathbf{x}_0)\, dx_i = \nabla f(\mathbf{x}_0) \cdot d\mathbf{x}$$

2.3 多元函数的线性近似及切超平面

由可微性的定义，函数在一点的局部线性近似由一个线性映射给出。这个线性近似函数的图像就是切超平面；它可以在整个坐标空间中定义，但通常不等于原函数。

$$df(\mathbf{x}_0) = \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\mathbf{x}_0)\, dx_i = \nabla f(\mathbf{x}_0) \cdot d\mathbf{x}$$

$$\Delta f(\mathbf{x}) \approx \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\mathbf{x}_0)\Delta x_i$$

$$f(\mathbf{x}) - f(\mathbf{x}_0) \approx \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\mathbf{x}_0)(x_i - x_{0i})$$

$$f(\vec{x}) \approx f(\vec{x}_0) + \sum_{i=1}^{n} \frac{\partial f(\vec{x}_0)}{\partial x_i}(x_i - x_{0i})$$

因此，切超平面对应的线性近似函数为：

$$L_{\mathbf{x}_0}(\mathbf{x}) = f(\mathbf{x}_0) + \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\mathbf{x}_0)(x_i - x_{0i})$$

$$L_{\mathbf{x}_0}(\mathbf{x}) = f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0) \cdot (\mathbf{x} - \mathbf{x}_0)$$

我们得到了线性近似和切超平面方程，但是有的时候我们需要更加精确的近似计算结果，从一元函数得到灵感，我们也可以使用多项式的方式去近似，即多元函数的泰勒展开。

我们显然需要定义出高阶导数, 多元函数中应该叫高阶全微分

2.4 多元函数的高阶全微分和泰勒展开

高阶全微分 尝试定义二阶全微分

$$df(\mathbf{x}_0) = \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\mathbf{x}_0)\, dx_i$$

$$d(df) = d\left(\sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\mathbf{x}_0)\, dx_i\right) = \sum_{i=1}^{n} d\left(\frac{\partial f}{\partial x_i}(\mathbf{x}_0)\, dx_i\right)$$

对于任意项:

$$d(\frac{\partial f}{\partial x_i}dx_i) = \sum_{j=1}^{n} \frac{\partial^2 f}{\partial x_i \partial x_j}dx_i dx_j$$

故:

$$d^2 f := d(df) = \sum_{i=1}^{n}\sum_{j=1}^{n} \frac{\partial^2 f}{\partial x_i \partial x_j}dx_i dx_j$$

若二阶偏导数连续有: $\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}$

介于上述一元函数全微分写成梯度形式 (矢量点成), 多元函数显然也可以写成类似形式。

这本质是二重求和的矩阵表达, 即二次型:

$$\sum_{i=1}^{n}\sum_{j=1}^{n} a_{ij}x_i x_j$$

它是由一个求和过程后再求和, 单一的求和问题可以转化为两个矩阵的乘积, 在对矩阵求和, 即转化成三个矩阵乘积.

$$\begin{aligned}
\sum_{i=1}^{n}\sum_{j=1}^{n} a_{ij}x_i x_j &= \sum_{i=1}^{n}\left(x_i(a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n)\right) \\
&= \sum_{i=1}^{n}\left(x_i \begin{pmatrix} a_{i1} & a_{i2} & \cdots & a_{in} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}\right) \\
&= \begin{pmatrix} x_1 & x_2 & \cdots & x_n \end{pmatrix} \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \\
&= \mathbf{x}^T A \mathbf{x}
\end{aligned}$$

若 f 在 $\mathbf{x}_0$ 附近二阶可微，则二阶导数 $D^2 f(\mathbf{x}_0)$ 是一个双线性映射。其在两个方向 $\mathbf{h}, \mathbf{k}$ 上的取值为

$$D^2 f(\mathbf{x}_0)[\mathbf{h}, \mathbf{k}] = \mathbf{h}^T H_f(\mathbf{x}_0)\mathbf{k}.$$

取两个方向相同，就得到二次型：

$$d^2 f(\mathbf{x}_0)[d\mathbf{x}, d\mathbf{x}] = (d\mathbf{x})^T H_f(\mathbf{x}_0) d\mathbf{x}.$$

其中 $H_f(\mathbf{x}_0)$ 是 Hessian 矩阵，它确定了二阶导数对应的二次型：

$$H_f(\mathbf{x}_0) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{x}_0)\right]_{i,j=1}^{n}$$

$$H_f(\mathbf{x}_0) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$$

符号上，有时记作 H 或 $\nabla^2 f$ **因此，二阶导数可以描述为二次型，沿用线性代数的结论我们可以判定多元函数极值**多元函数的极值问题-> 二阶导数的正负-> 特征值或 Sylvester 判据

二次型的符号可以由下列方法判定

1. 特征值法
2. Sylvester 判据

特征值法 Hessian 矩阵 $H_f(\mathbf{x}_0)$ 是一个对称矩阵，根据线性代数的性质，它可以被正交对角化。也就是说，存在一个正交矩阵 P （满足 $P^TP = I$ ），使得：

$$(d\mathbf{x})^T H_f(\mathbf{x}_0) d\mathbf{x} = (d\mathbf{x})^T (PDP^T) d\mathbf{x} = (P^T d\mathbf{x})^T D (P^T d\mathbf{x}) = \mathbf{w}^T D \mathbf{w}$$

由于 D 是对角矩阵，展开后有：

$$\mathbf{w}^T D \mathbf{w} = \sum_{i=1}^{n} \lambda_i w_i^2$$

- **正定**：如果所有特征值 $\lambda_i > 0$ ，则对于任意非零向量 $d\mathbf{x}$ ，有 $\sum_{i=1}^{n} \lambda_i w_i^2 > 0$ ，因此 $H_f(\mathbf{x}_0)$ 是正定的。此时，函数 f 在 $\mathbf{x}_0$ 处有局部极小值。
- **负定**：如果所有特征值 $\lambda_i < 0$ ，则 $\sum_{i=1}^{n} \lambda_i w_i^2 < 0$ ，$H_f(\mathbf{x}_0)$ 是负定的，函数 f 在 $\mathbf{x}_0$ 处有局部极大值。
- **不定**：如果特征值中既有正值又有负值，则 $\sum_{i=1}^{n} \lambda_i w_i^2$ 的符号取决于 $\mathbf{w}$ 的选择。例如，可以选择 $w_i \neq 0$ 仅对应正特征值，使和为正；或仅对应负特征值，使和为负。因此，$H_f(\mathbf{x}_0)$ 是不定的，$\mathbf{x}_0$ 是鞍点。
- **半定**：如果特征值中有零，则 $\sum_{i=1}^{n} \lambda_i w_i^2$ 可能为零或非零，具体取决于 $\mathbf{w}$ 。此时需要进一步分析，但通常不足以确定严格的极值。

Sylvester 判据 对于 $n \times n$ 的对称矩阵 $H_f(\mathbf{x}_0)$ ，其 k 阶主子式 Δ_k 定义为左上角 $k \times k$ 子矩阵的行列式：

$$\Delta_k = \det \begin{pmatrix} h_{11} & h_{12} & \cdots & h_{1k} \\ h_{21} & h_{22} & \cdots & h_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ h_{k1} & h_{k2} & \cdots & h_{kk} \end{pmatrix}$$

其中，$h_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{x}_0)$ 。

- **正定**：$H_f(\mathbf{x}_0)$ 是正定的，当且仅当所有主子式 $\Delta_k > 0$ （$k = 1, 2, \ldots, n$ ）。
- **负定**：$H_f(\mathbf{x}_0)$ 是负定的，当且仅当主子式的符号交替，即 $(-1)^k \Delta_k > 0$ ：
- $\Delta_1 < 0$ （当 $k = 1$ 时）
- $\Delta_2 > 0$ （当 $k = 2$ 时）
- $\Delta_3 < 0$ （当 $k = 3$ 时）
- 依此类推。
- **其他情况**：如果主子式不满足上述条件，则 $H_f(\mathbf{x}_0)$ 可能是半正定、半负定或不定。

综上，二阶判别法必须先在临界点满足 $\nabla f(\mathbf{x}_0) = 0$，再根据 Hessian 矩阵的正定性判断局部曲率。正定给出严格局部极小值，负定给出严格局部极大值，不定给出鞍点；半正定或半负定时，二阶判别法通常无法作出结论。

多元函数的泰勒展开 由此我们给出**多元函数的泰勒展开**:

设 $f:\mathbb{R}^n \to \mathbb{R}$ 在包含 $\mathbf{x}_0$ 的邻域内具有二阶连续偏导数，记 $\mathbf{h}=\mathbf{x}-\mathbf{x}_0$，则二阶 Taylor 公式为：

$$f(\mathbf{x}_0+\mathbf{h})=f(\mathbf{x}_0)+Df(\mathbf{x}_0)[\mathbf{h}]+\frac{1}{2}D^2f(\mathbf{x}_0)[\mathbf{h},\mathbf{h}]+o(\|\mathbf{h}\|^2)$$

在 f 二阶可微时，上式写成矩阵形式为：

$$f(\mathbf{x}_0+\mathbf{h})=f(\mathbf{x}_0)+Df(\mathbf{x}_0)[\mathbf{h}]+\frac{1}{2}D^2f(\mathbf{x}_0)[\mathbf{h},\mathbf{h}]+o(\|\mathbf{h}\|^2)$$

即：

$$f(\mathbf{x}_0+\mathbf{h})=f(\mathbf{x}_0)+\nabla f(\mathbf{x}_0)^T\mathbf{h}+\frac{1}{2}\mathbf{h}^TH_f(\mathbf{x}_0)\mathbf{h}+o(\|\mathbf{h}\|^2)$$

以上我们完成了多元函数的微分描述任务 ($\mathbb{R}^n \to \mathbb{R}$) , 更进一步的, 我们需要考虑向量值函数的微分描述 ($\mathbb{R}^n \to \mathbb{R}^m$)

3 向量值函数

向量值函数（或向量函数）是将一个标量或向量输入映射到向量输出的函数。具体定义如下：

3.1 定义

设 $\mathbf{x}=[x_1,x_2,\dots,x_m]^T\in\mathbb{R}^m$ 是一个 m 维向量（或标量当 $m=1$ ），向量值函数 $\mathbf{f}$ 定义为：

$$\mathbf{f}:\mathbb{R}^m\to\mathbb{R}^n$$

其中，输出是一个 n 维向量：

$$\mathbf{f}(\mathbf{x})=\begin{bmatrix}f_1(x_1,x_2,\dots,x_m)\\ f_2(x_1,x_2,\dots,x_m)\\ \vdots\\ f_n(x_1,x_2,\dots,x_m)\end{bmatrix}$$

这里的每个分量 $f_i:\mathbb{R}^m\to\mathbb{R}$ （$i=1,2,\dots,n$ ）是一个标量函数。

所以研究向量值函数的微分本质就是在研究标量函数的微分 (即前面的多元函数章节)。

3.2 向量值函数的全微分

$$
\begin{aligned}
d\mathbf{f}(\mathbf{x}_0) &= \begin{pmatrix} df_1(\mathbf{x}_0) \\ df_2(\mathbf{x}_0) \\ \vdots \\ df_n(\mathbf{x}_0) \end{pmatrix} \\
&= \begin{pmatrix} \sum_{i=1}^{m} \frac{\partial f_1}{\partial x_i}(\mathbf{x}_0)\, dx_i \\ \sum_{i=1}^{m} \frac{\partial f_2}{\partial x_i}(\mathbf{x}_0)\, dx_i \\ \vdots \\ \sum_{i=1}^{m} \frac{\partial f_n}{\partial x_i}(\mathbf{x}_0)\, dx_i \end{pmatrix} \\
&= \begin{pmatrix} \frac{\partial f_1}{\partial x_1}(\mathbf{x}_0) & \frac{\partial f_1}{\partial x_2}(\mathbf{x}_0) & \cdots & \frac{\partial f_1}{\partial x_m}(\mathbf{x}_0) \\ \frac{\partial f_2}{\partial x_1}(\mathbf{x}_0) & \frac{\partial f_2}{\partial x_2}(\mathbf{x}_0) & \cdots & \frac{\partial f_2}{\partial x_m}(\mathbf{x}_0) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1}(\mathbf{x}_0) & \frac{\partial f_n}{\partial x_2}(\mathbf{x}_0) & \cdots & \frac{\partial f_n}{\partial x_m}(\mathbf{x}_0) \end{pmatrix} \begin{pmatrix} dx_1 \\ dx_2 \\ \vdots \\ dx_m \end{pmatrix} \\
&= J_{\mathbf{f}}(\mathbf{x}_0)\, d\mathbf{x}
\end{aligned}
$$

其中 $J_{\mathbf{f}}(\mathbf{x}_0)$ 为函数 $\mathbf{f}$ 在点 $\mathbf{x}_0$ 处的雅可比矩阵（Jacobian matrix），定义为：

$$
J_{\mathbf{f}}(\mathbf{x}) = \left[\frac{\partial f_i}{\partial x_j}(\mathbf{x}) \right]_{n \times m}
$$

当 $n = 1$ 时,Jacobian 矩阵退化成

$$
J_{\mathbf{f}}(\mathbf{x}) = \left[\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \ldots, \frac{\partial f}{\partial x_m} \right]
$$

这正是梯度 ∇f 的转置 $(\nabla f)^T$ 。不过，梯度通常定义为列向量，所以 $J_{\mathbf{f}} = (\nabla f)^T$ 。

因此:Jacobian 矩阵是梯度的向量值形式，即每个分量的梯度构成的矩阵。 Jacobian 矩阵是向量值函数的一阶导数矩阵。相对的梯度是 Jacobian 的标量情形。

特别的, 注意到:

- **Hessian 和 Jacobian：** Hessian 矩阵可以看作是梯度 ∇f 的 Jacobian 矩阵。计算 ∇f （一个 $m \times 1$ 向量）的 Jacobian：

$$
J_{\nabla f} = \begin{bmatrix} \frac{\partial}{\partial x_1}\left(\frac{\partial f}{\partial x_1}\right) & \cdots & \frac{\partial}{\partial x_m}\left(\frac{\partial f}{\partial x_1}\right) \\ \vdots & \ddots & \vdots \\ \frac{\partial}{\partial x_1}\left(\frac{\partial f}{\partial x_m}\right) & \cdots & \frac{\partial}{\partial x_m}\left(\frac{\partial f}{\partial x_m}\right) \end{bmatrix} = H_f
$$

Hessian 是梯度的梯度 (二阶变化量)，梯度是矢量，因此对梯度 (矢量) 求导 (即取 Jacobian) 即得 Hessian 矩阵。

因此，$H_f = J_{\nabla f}$ ，Hessian 是梯度的一阶导数矩阵。 $H_f = J_{\nabla f}$ 的数学本质在于，Hessian 矩阵是梯度 ∇f 的 Jacobian 矩阵，**体现了二阶导数对一阶导数的依赖关系**。它不仅提供了函数的二阶变化信息，还在几何、优化和物理学中具有重要意义，反映了函数的局部性质和行为。

3.3 向量值函数的线性近似

通俗地，$J_{\mathbf{f}}$ 在每一点给出了 $\mathbf{f}$ 的线性近似。例如，当 $\mathbf{f}$ 在某点 p 可微时，$J_{\mathbf{f}}(p)$ 就是 $\mathbf{f}$ 在该点的导数，即在该点的最佳线性逼近。换言之，当 $\mathbf{x}$ 足够接近 p 时，有

$$\mathbf{f}(\mathbf{x}) \approx \mathbf{f}(p) + J_{\mathbf{f}}(p) \cdot (\mathbf{x} - p).$$

3.4 向量值函数的泰勒展开

为了在向量值函数中引入高阶近似，我们同样对标量情形的泰勒展开进行推广。设

$$\mathbf{f} : \mathbb{R}^m \to \mathbb{R}^n, \quad \mathbf{x}_0 \in \mathbb{R}^m, \quad \mathbf{h} = \mathbf{x} - \mathbf{x}_0$$

当 $\|\mathbf{h}\|$ 足够小时，$\mathbf{f}(\mathbf{x}_0 + \mathbf{h})$ 可展开为：

$$\boxed{\mathbf{f}(\mathbf{x}_0 + \mathbf{h}) = \mathbf{f}(\mathbf{x}_0) + \underbrace{J_{\mathbf{f}}(\mathbf{x}_0)\mathbf{h}}_{\text{一阶线性项}} + \underbrace{\frac{1}{2}\begin{pmatrix} \mathbf{h}^T H_{f_1}(\mathbf{x}_0)\mathbf{h} \\ \mathbf{h}^T H_{f_2}(\mathbf{x}_0)\mathbf{h} \\ \vdots \\ \mathbf{h}^T H_{f_n}(\mathbf{x}_0)\mathbf{h} \end{pmatrix}}_{\text{二阶二次型项}} + o(\|\mathbf{h}\|^2)}$$

- **常数项 $\mathbf{f}(\mathbf{x}_0)$ ：**函数在展开点的原始值。
- **一阶线性项 $J_{\mathbf{f}}(\mathbf{x}_0)\,\mathbf{h}$：**由雅可比矩阵给出，是向量值映射在该点的导数，即最佳线性近似。对于参数化曲面，它的像空间与切空间有关。
- **二阶二次型项：**每个分量 f_i 的二阶导数构成 Hessian 矩阵 H_{f_i} ，并通过 $\mathbf{h}^T H_{f_i}\mathbf{h}$ 给出二阶校正。将所有分量组合，即得到上述向量形式。
- **余项 $o(\|\mathbf{h}\|^2)$ ：**高于二阶的小量。

张量形式　我们也可用三阶张量 $\mathcal{H}$ 一次性描述所有分量的二阶导数：令

$$\mathcal{H} \in \mathbb{R}^{n\times m\times m}, \quad \mathcal{H}_{i,j,k} = \frac{\partial^2 f_i}{\partial x_j \partial x_k}(\mathbf{x}_0)$$

则二阶项可写作：

$$\left(\mathcal{H}[\mathbf{h},\mathbf{h}]\right)_i = \sum_{j,k=1}^{m} \mathcal{H}_{i,j,k}\, h_j\, h_k$$

整体展开为：

$$\mathbf{f}(\mathbf{x}_0 + \mathbf{h}) = \mathbf{f}(\mathbf{x}_0) + J_{\mathbf{f}}(\mathbf{x}_0)\mathbf{h} + \frac{1}{2}\mathcal{H}[\mathbf{h},\mathbf{h}] + o(\|\mathbf{h}\|^2)$$

这种张量写法在多维高阶分析和自动微分中十分常见。

综上所述:

$$f:\mathbb{R}\to\mathbb{R},\quad Df(x_0)[h]=f'(x_0)h,\quad D^2f(x_0)[h,h]=f''(x_0)h^2$$
$$f:\mathbb{R}^n\to\mathbb{R},\quad Df(x_0)[h]=\nabla f(x_0)^Th,\quad D^2f(x_0)[h,h]=h^TH_f(x_0)h$$
$$\mathbf{f}:\mathbb{R}^m\to\mathbb{R}^n,\quad D\mathbf{f}(x_0)[h]=J_{\mathbf{f}}(x_0)h,$$
$$D^2\mathbf{f}(x_0)[h,h]=\begin{pmatrix}h^TH_{f_1}(x_0)h\\ h^TH_{f_2}(x_0)h\\ \vdots\\ h^TH_{f_n}(x_0)h\end{pmatrix}$$

4 线性变换与微分

4.1 线性变换

定义

- **可加性（Additivity）**：$\vec{u},\vec{v}\in V$，
$$T(\vec{u}+\vec{v})=T(\vec{u})+T(\vec{v})$$
- **齐次性（Homogeneity）**：对于任意标量 c 和向量 $\vec{u}\in V$，
$$T(c\vec{u})=cT(\vec{u})$$

结合上述性质，线性变换可以写为：

$$T(c_1\vec{u}+c_2\vec{v})=c_1T(\vec{u})+c_2T(\vec{v})$$

原空间中任意向量都可以写成基向量的线性组合，而线性变换又具有线性性，因此变换由基向量的像唯一决定，即线性组合的结构得以保持。具体表现为

$$T(\sum_{i=1}^{n}x_ie_i)=\sum_{i=1}^{n}T(x_ie_i)=\sum_{i=1}^{n}x_iT(e_i)$$

而这种线性组合问题恰巧可以使用矩阵语言来描述: 在有限维向量空间（如 $\mathbb{R}^n\to\mathbb{R}^m$ ）中，线性变换可以用矩阵表示。

矩阵表示　设线性变换 $T:\mathbb{R}^n\to\mathbb{R}^m$ ，且 $\{e_1,e_2,\dots,e_n\}$ 是 $\mathbb{R}^n$ 的标准基。由线性性可知：

$$T(\vec{x})=T\left(\sum_{i=1}^{n}x_ie_i\right)=\sum_{i=1}^{n}x_iT(e_i)$$

我们记：

$A=[T(e_1)\quad T(e_2)\quad\cdots\quad T(e_n)]$ （$m\times n$ 矩阵，每列为 T 作用于基向量的结果）

具体的

$$A = \begin{bmatrix} | & | & & | \\ T(e_1) & T(e_2) & \cdots & T(e_n) \\ | & | & & | \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

设有一向量 $\vec{x} = \{x_1, x_2 \cdots x_n\}$ ，则：

$$T(\vec{x}) = A\vec{x}$$

这意味着**每一个从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的线性变换都可以唯一对应一个 $m \times n$ 的矩阵**，并且我们可以通过只分析基向量的变化而得到 A，从而使线性变换转化为矩阵乘法问题。

在线性代数中，我们有如下重要结论

- $A[v_1\ v_2] = [Av_1\ Av_2]$
- $\det(AB) = \det(A)\det(B)$

$A[v_1\ v_2] = [Av_1\ Av_2]$ 表明对列向量矩阵 $[v_1\ v_2]$ 中的向量分别进行线性变化**等价于**对整个列向量矩阵进行线性变换。(矩阵乘法定义本身，线性变换的对矩阵每一列的独立作用) $\det(AB) = \det(A)\det(B)$ 表明对单位体积 (单位矢量张成) 进行线性变换 B 再进行线性变换 A 后张成的体积**等价于**原单位体积放缩 B 倍再放缩 A 倍。(反映了线性变换在体积缩放上的复合效应)

4.2 微分与线性变换

根据上面对微分的研究，微分其本身就是一个局部的线性近似，自然的将一个非线性的映射的局部线性性表现出来:

$$f(x_0 + h) \approx f(x_0) + J_f(x_0)h$$

当我们用微分的视角去看发现微分运算本身就是一个线性变换:

$$d\mathbf{f}(\mathbf{x}_0) = J_{\mathbf{f}}(\mathbf{x}_0)\, d\mathbf{x}$$

根据线性代数的知识我们知道，Jacobian 矩阵就是该局部线性变换的具体描述。该描述可以表征某区域的缩放因子从而应用于多元积分的换元。

4.3 多元函数积分的换元法

在多元函数积分的换元法中，雅可比矩阵（Jacobian matrix）用于描述变量变换时积分元素的变换规律。以下是利用雅可比矩阵进行多元函数积分换元的推导与公式：

1. 多元积分换元的基本思想

假设有一个多元函数 $f(\mathbf{x})$ ，其中 $\mathbf{x} = (x_1, x_2, \ldots, x_n) \in \mathbb{R}^n$ ，我们希望通过变量变换 $\mathbf{x} = \mathbf{g}(\mathbf{u})$ ，其中 $\mathbf{u} = (u_1, u_2, \ldots, u_n) \in \mathbb{R}^n$ ，将积分区域和被积函数转换为新的变量 $\mathbf{u}$ 。积分的换元公式为：

$$\int_{\Omega} f(\mathbf{x})\, d\mathbf{x} = \int_{\mathbf{g}^{-1}(\Omega)} f(\mathbf{g}(\mathbf{u}))\, \left|\det J_{\mathbf{g}}(\mathbf{u})\right|\, d\mathbf{u},$$

其中：

- $\Omega \subset \mathbb{R}^n$ 是原始积分区域；
- $\mathbf{g} : U \subset \mathbb{R}^n \to \mathbb{R}^n$ 是满足适当光滑性和可逆性条件的同维变换；
- $J_{\mathbf{g}}(\mathbf{u})$ 是变换 $\mathbf{g}$ 在点 $\mathbf{u}$ 处的雅可比矩阵；
- $\left|\det J_{\mathbf{g}}(\mathbf{u})\right|$ 是雅可比矩阵行列式的绝对值，称为**雅可比因子**，它表征了局部体积的缩放比例。

雅可比矩阵的定义对于变换 $\mathbf{x} = \mathbf{g}(\mathbf{u})$ ，其中 $\mathbf{g} = (g_1, g_2, ..., g_n)$ ，雅可比矩阵 $J_{\mathbf{g}}(\mathbf{u})$ 定义为：

$$J_{\mathbf{g}}(\mathbf{u}) = \begin{bmatrix} \frac{\partial g_1}{\partial u_1} & \frac{\partial g_1}{\partial u_2} & \cdots & \frac{\partial g_1}{\partial u_n} \\ \frac{\partial g_2}{\partial u_1} & \frac{\partial g_2}{\partial u_2} & \cdots & \frac{\partial g_2}{\partial u_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial g_n}{\partial u_1} & \frac{\partial g_n}{\partial u_2} & \cdots & \frac{\partial g_n}{\partial u_n} \end{bmatrix}.$$

这个矩阵描述了从 $\mathbf{u}$ 空间到 $\mathbf{x}$ 空间的局部线性变换。

体积元素变换推导：

设 $\vec{x} = \mathbf{g}(\vec{u})$ 是从 $\vec{u}$ 空间到 $\vec{x}$ 空间的可微变换，那么：

$$d\vec{x} = J_{\mathbf{g}}(\vec{u})\, d\vec{u}$$

原空间中体积元素（$\vec{u}$ 空间）为：

$$dV_{\vec{u}} = |\det([d\vec{u}_1\ d\vec{u}_2\ \cdots\ d\vec{u}_n])|$$

变换后在 $\vec{x}$ 空间中的体积元素为：

$$\begin{aligned} dV_{\vec{x}} &= |\det([d\vec{x}_1\ d\vec{x}_2\ \cdots\ d\vec{x}_n])| \\ &= \left|\det([J_{\mathbf{g}} d\vec{u}_1\ J_{\mathbf{g}} d\vec{u}_2\ \cdots\ J_{\mathbf{g}} d\vec{u}_n])\right| \\ &= \left|\det(J_{\mathbf{g}}) \cdot \det([d\vec{u}_1\ d\vec{u}_2\ \cdots\ d\vec{u}_n])\right| \\ &= \left|\det(J_{\mathbf{g}}(\vec{u}))\right| \cdot dV_{\vec{u}} \end{aligned}$$

几何解释

- 雅可比矩阵 $J_{\mathbf{g}}(\mathbf{u})$ 表示变换 $\mathbf{g}$ 在 $\mathbf{u}$ 处的局部线性近似。
- 当对一个微小区域 $d\mathbf{u}$ 应用变换 $\mathbf{g}$ 时，$\mathbf{u}$ 空间中的微小体积元素会被映射到 $\mathbf{x}$ 空间，其体积变化的比例由 $\left|\det J_{\mathbf{g}}(\mathbf{u})\right|$ 决定。